HACKATHON
IA X RH

INTRODUCTION

OBJECTIF

- **Contexte** : Une entreprise imaginaire fait face à un taux de démissions élevé et veut utiliser l'IA pour mieux comprendre les causes du turnover et préserver ses talents.
- **Produit** :
  - Solution d'IA qui aide les RH à retenir ses talents
  - Faire découvrir car quatre grands thèmes de l'IA grâce à une problématique (Choisir deux thèmes)

IA & Cybersécurité
Sécuriser les données RH (anonymisation, conformité RGPD) et prévenir les attaques IA (ex: *prompt injection*).

IA Éthique
Éviter les biais algorithmiques et les discriminations. Un modèle formé sur des données biaisées peut produire des résultats injustes envers certains groupes.

IA Frugale
Optimiser l'IA pour qu'elle soit sobre en ressources. L'IA frugale vise des systèmes plus économes en énergie et en données, tout en restant efficaces.

IA Explicable
Rendre les modèles explicables et transparents. L'IA explicable fournit des méthodes pour que les humains comprennent et fassent confiance aux résultats produits par l'algorithme.

DONNÉES

▸ **Contexte** :
Vous disposez d'un **jeu de données RH open source** (inspiré du dataset Kaggle de Rich Huebner) contenant des informations sur ~400 employés (âge, poste, salaire, performance, etc.) et leur statut (toujours en poste ou **démissionnaire/terminé** : champ Termd et motif de départ TermReason).

Ces données synthétiques incluent notamment des attributs *sensibles* comme le **sexe** (Sex = M/F) ou l'**ethnie** (RaceDesc) des employés.

Kaggle : Human Resources Data Set
Description :
Le jeu de données RH a été conçu par les Drs Rich Huebner et Carla Patalano pour accompagner une étude de cas destinée aux étudiants diplômés en RH étudiant les métriques, la mesure et l'analytique des RH. Les élèves utilisent le logiciel de visualisation de données Tableau pour découvrir des informations sur le cas. Il s'agit d'un ensemble de données synthétiques créé spécifiquement pour accompagner l'étude de cas (propriétaire pour l'établissement où nous enseignons).

Data Dictionary

ï..Feature	Description	DataType
Employee Name	Employee's full name	Text
EmpID	Employee ID is unique to each employee	Text
MarriedID	Is the person married (1 or 0 for yes or no)	Binary
MaritalStatusID	Marital status code that matches the text field MaritalDesc	Integer
EmpStatusID	Employment status code that matches text field EmploymentStatus	Integer
DeptID	Department ID code that matches the department the employee works in	Integer
PerfScoreID	Performance Score code that matches the employee's most recent performance score	Integer
FromDiversityJobFairID	Was the employee sourced from the Diversity job fair? 1 or 0 for yes or no	Binary
PayRate	The person's hourly pay rate. All salaries are converted to hourly pay rate	Float
Termd	Has this employee been terminated - 1 or 0	Binary
PositionID	An integer indicating the person's position	Integer
Position	The text name/title of the position the person has	Text
State	The state that the person lives in	Text
Zip	The zip code for the employee	Text
DOB	Date of Birth for the employee	Date
Sex	Sex - M or F	Text
MaritalDesc	The marital status of the person (divorced, single, widowed, separated, etc)	Text
CitizenDesc	Label for whether the person is a Citizen or Eligible NonCitizen	Text
HispanicLatino	Yes or No field for whether the employee is Hispanic/Latino	Text
RaceDesc	Description/text of the race the person identifies with	Text
DateofHire	Date the person was hired	Date
DateofTermination	Date the person was terminated, only populated if, in fact, Termd = 1	Date
TermReason	A text reason / description for why the person was terminated	Text
EmploymentStatus	A description/category of the person's employment status. Anyone currently working full time = Active	Text

DÉFI

▸ **Obstacle** :

Pour enrichir l'analyse, vous pouvez intégrer également des **données textuelles** (simulées par IA gen ou base dispo) , par exemple : des **demandes de mutation interne** rédigées par certains employés, et des extraits anonymisés de **feedbacks RH** (commentaires d'entretiens de sortie, remarques dans des enquêtes de satisfaction).
Définition :

- Définition les UC, les personae par les étudiants.
    - Exemple :
        - UC: Analyse de la démission des employés
        - Personae : «je suis le client j'ai besoin d'une solution pour retenir mes employés / Je suis l'entreprise HR-AI, j'apporte des solutions IA pour les RH»
- Ces textes permettront d'explorer des approches de *NLP classique* (analyse de sentiment, extraction de thèmes…) **et** d'**IA générative** (par ex. utiliser un modèle de langage pour résumer des feedbacks ou répondre à des questions).

➔ L'intégration de données non-structurées offre, une occasion de se confronter à des problèmes de compréhension du langage naturel, tout en ajoutant une dimension réaliste (les raisons d'un départ ne se résument pas à des chiffres, le contexte qualitatif compte).

▸ **Défi à relever** :

Vous devez concevoir une solution IA pour aider la direction RH à identifier les facteurs de démission et à suggérer des actions préventives.
Par Exemple : prédire quels employés risquent de quitter la société et expliquer pourquoi, en s'appuyant à la fois sur les données structurées (chiffre/mesures) et sur l'analyse des textes fournis. Le tout doit se faire en respectant une IA responsable :

- Protection des données et cybersécurité (les données du personnel sont sensibles)
- Éthique et non-discrimination (ne pas reproduire de biais injustes)
- Frugalité (utiliser les ressources de façon efficiente, privilégier des solutions sobres)
- Explicabilité (fournir aux RH des résultats transparents et justifiables).

IA CYBERSECURITÉ

▸ **Données** :
Sécurité des données : Réfléchissez aux règlementations des données
Les données que vous manipulez, sont-elles sensibles ? Pourquoi ?

Action : Par mesure de conformité RGPD, le jeu de données fourni doit etre anonymisé (noms modifiés ou codifiés, emails supprimés, etc.), car l'anonymisation des données personnelles (suppression ou masquage des identifiants sensibles) est essentielle pour rester en conformité légale.

▸ **IA** :
La reglementation IA Act demande la transparence et la mesure du niveau de risque de mon IA. Quel est mon niveau de risques ?
Est-ce que mon ia est protegé des attaques ?

Action : Test de mes IA sur les attaques typiques

Core Anonymization Techniques

- **Generalization**
  - ✓ Replace specific values with broader categories.
- **Suppression**
  - ✓ Remove sensitive data or entire records.
- **Masking**
  - ✓ Hide parts of data values while preserving format.
- **Perturbation**
  - ✓ Introduce controlled noise to modify data.
- **Pseudonymization**
  - ✓ Replace real identifiers with artificial codes.
- **Synthetic Data**
  - ✓ Generate new records mirroring real data's statistics.

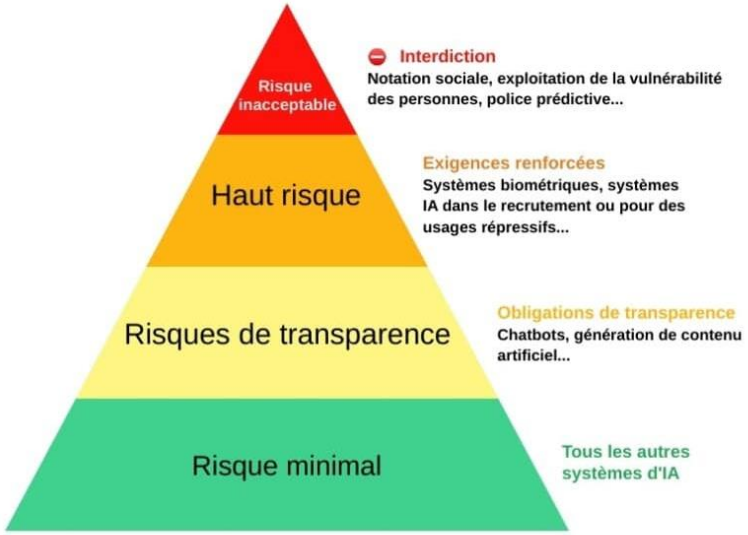

IA ETHIQUE

▸ **Objectif** :
IA Éthique & biais algorithmiques : Une fois que les premiers modèles commencent à être construits (par ex. un modèle de machine learning qui anticipe le risque de démission à partir des variables du dataset), il est crucial de se questionner sur la **fairness** de ces modèles.

Défi "IA responsable": qu'est qu'un model « fair » équitable ? Auditer les prédictions : par exemple, vérifier si le modèle traite équitablement tous les employés ou s'il présente des signes de discrimination.

Outil Opensource : aif360.res.ibm.com

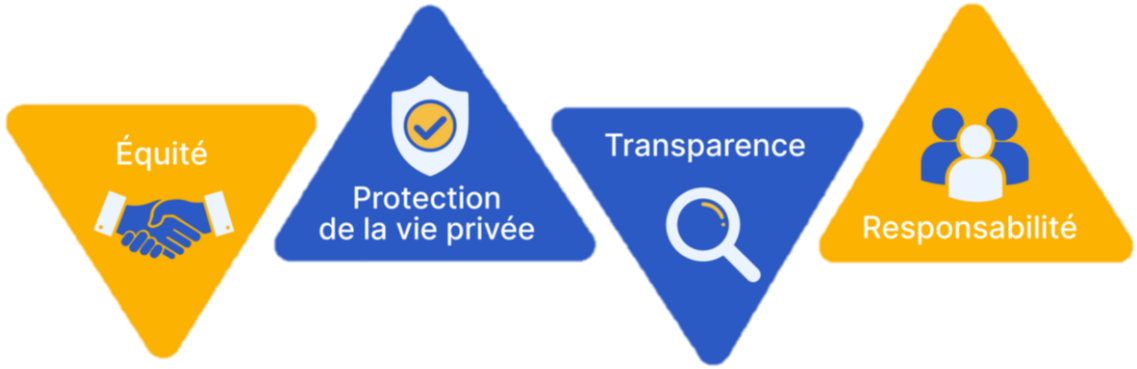

IA FRUGAL

▸ **Obstacle** :

IA Frugale & efficacité des ressources : Une fois un modèle fonctionnel établi, un nouveau défi s'offre à vous
Celui d'**améliorer l'efficacité** de votre solution sans trop sacrifier les performances.
Plusieurs axes peuvent être explorés :
Frugalité des données : le dataset de base est de taille modeste
Frugalité des modèles : comparer des approches **simples vs. Complexes.**
Sobriété énergétique : les calculs restent modestes, mais c'est l'occasion de les conscientiser à l'**impact environnemental de l'IA**.
On peut aussi discuter de **techniques frugales** : compression de modèle, quantification, etc., dans l'optique où leur solution devrait un jour tourner sur un serveur de l'entreprise avec des ressources limitées.

L'atelier **IA frugale :** Présentation des modèles plus légers et durables au lieu de toujours foncer vers des solutions complexes énergivores.

Code Carbon est une bibliothèque open source conçue pour mesurer et réduire l'empreinte carbone.
Ecologits est une bibliothèque qui permet d'estimer l'émission carbon d'un model llm
ComparAI outil de comparaison d'IA conversationnelle.

EcoLogits

Estimate and track the environmental footprint of GenAI models at inference.

Made with 💚 by GenAI Impact non-profit.

IA EXPLICABLE

▸ **Obstacle** :

IA Explicable & transparence : Ici, l'enjeu est que votre solution ne soit pas une "boîte noire" incompréhensible pour les responsables RH qui vont l'utiliser.
On encourage donc fortement l'intégration de techniques d'explication des modèles :
➔ Côté modèle prédictif (structuré) : Si vous avez utilisé un modèle de machine learning, analysez les facteurs d'influence.
Par exemple : "notre modèle prédit que l'employé X va démissionner parce que son score de satisfaction est faible et qu'il a eu de nombreux retards récemment".
Techniquement, utilisez des outils d'XAI comme LIME ou SHAP pour expliquer les prédictions.

➔ Côté IA générative/NLP : si vous avez construit un outil type chatbot ou un système de résumé automatique des feedbacks employés, l'explicabilité concerne la transparence du fonctionnement et des limites. Vous devez donc documenter comment votre modèle génère ses réponses (par ex. indiquer qu'il se base sur GPT-3 ou sur tel modèle fine-tuné, entraîné sur tels types de données) et d'alerter sur les éventuelles hallucinations ou erreurs possibles.

Atelier "règles d'or" de l'IA explicable. Methode et outil pour la transparence des models.

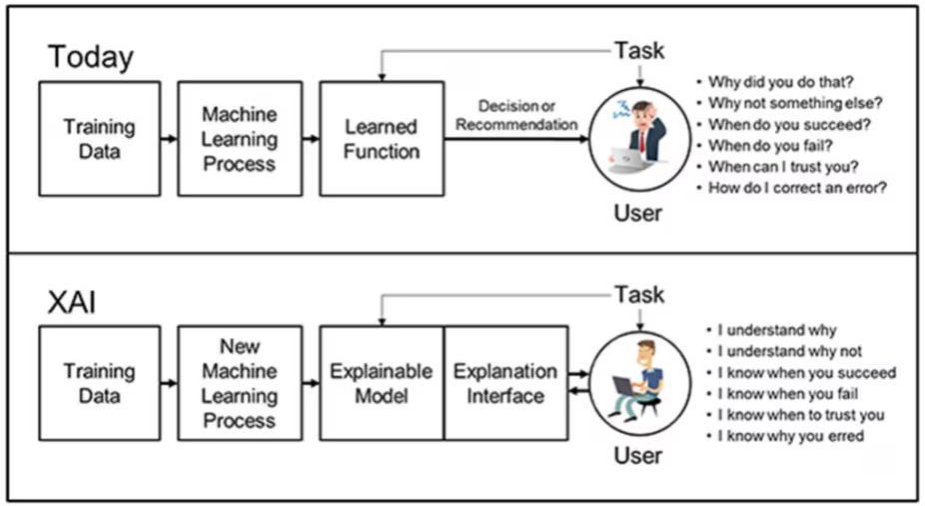

HACKATHON
TRUSTED AI X RH

INTRODUCTION

OBJECTIVE

- **Background :** An imaginary company is facing HR issues and wants to use AI to better understand the causes of turnover and preserve its talent.
- **Product** :
  - AI solution that helps HR to manage talents
  - To help people discover four major themes of AI through a problem (Choose two themes)

AI & Cybersecurity
Secure HR data (anonymization, GDPR compliance) and prevent AI attacks (e.g. prompt injection).

Ethics AI
Avoid algorithmic bias and discrimination. A model trained on biased data can produce unfair results towards certain groups.

Frugal AI
Optimize AI to be resource-efficient. Frugal AI aims for systems that are more energy and data-efficient, while remaining efficient.

Explainable AI
Make models explainable and transparent. Explainable AI provides methods for humans to understand and trust the results produced by the algorithm.

DATA

▸ **Context** :

You have an open-source **HR dataset** (inspired by Rich Huebner's Kaggle dataset) containing information on ~400 employees (age, position, salary, performance, etc.) and their status (still on or resigning/terminated: Termd field and TermReason for leaving).
This synthetic data includes **sensitive attributes** such as the gender (Sex = M/F) or the ethnicity (RaceDesc) of the employees.
Kaggle : Human Resources Data Set

Description :

The HR dataset was designed by Drs. Rich Huebner and Carla Patalano to accompany a case study for HR graduate students studying HR metrics, measurement, and analytics. Students use Tableau data visualization software to uncover information about the case. This is a synthetic dataset created specifically to accompany the case study (proprietary for the institution where we teach).

Data Dictionary

ï..Feature	Description	DataType
Employee Name	Employee's full name	Text
EmpID	Employee ID is unique to each employee	Text
MarriedID	Is the person married (1 or 0 for yes or no)	Binary
MaritalStatusID	Marital status code that matches the text field MaritalDesc	Integer
EmpStatusID	Employment status code that matches text field EmploymentStatus	Integer
DeptID	Department ID code that matches the department the employee works in	Integer
PerfScoreID	Performance Score code that matches the employee's most recent performance score	Integer
FromDiversityJobFairID	Was the employee sourced from the Diversity job fair? 1 or 0 for yes or no	Binary
PayRate	The person's hourly pay rate. All salaries are converted to hourly pay rate	Float
Termd	Has this employee been terminated - 1 or 0	Binary
PositionID	An integer indicating the person's position	Integer
Position	The text name/title of the position the person has	Text
State	The state that the person lives in	Text
Zip	The zip code for the employee	Text
DOB	Date of Birth for the employee	Date
Sex	Sex - M or F	Text
MaritalDesc	The marital status of the person (divorced, single, widowed, separated, etc)	Text
CitizenDesc	Label for whether the person is a Citizen or Eligible NonCitizen	Text
HispanicLatino	Yes or No field for whether the employee is Hispanic/Latino	Text
RaceDesc	Description/text of the race the person identifies with	Text
DateofHire	Date the person was hired	Date
DateofTermination	Date the person was terminated, only populated if, in fact, Termd = 1	Date
TermReason	A text reason / description for why the person was terminated	Text
EmploymentStatus	A description/category of the person's employment status. Anyone currently working full time = Active	Text

CHALLENGES

▸ **Obstacle** :

To enrich the analysis, you can also integrate textual data (simulated by AI gen or available database), for example: internal transfer requests written by certain employees, and anonymized extracts of HR feedback (comments from exit interviews, remarks in satisfaction surveys).
Définition :

- Definition of UCs, personae by students.
  - Exemple :
    - UC: Employee Resignation Analysis
    - Personae : "I am the customer I need a solution to retain my employees / I am the HR-AI company, I bring AI solutions for HR.

These texts will explore approaches to classic NLP (sentiment analysis, theme extraction, etc.) and generative AI (e.g. using a language model to summarize feedback or answer questions).

➔ The integration of unstructured data offers an opportunity to confront natural language understanding problems, while adding a realistic dimension (the reasons for leaving are not just numbers, the qualitative context counts).

▸ **Challenge ahead**:

You need to design an AI solution to help HR management identify the factors behind resignation and suggest preventive actions.
For example: predicting which employees are at risk of leaving the company and explaining why, based on both structured data (numbers/metrics) and analysis of the texts provided. Everything must be done in accordance with responsible AI:

- Data protection and cybersecurity (staff data is sensitive)
- Ethics and non-discrimination (do not reproduce unfair biases)
- Frugality (use resources efficiently, favor sober solutions)
- Explainability (providing HR with transparent and defensible results).

IA CYBERSECURITY

Data:

Data security: Think about data regulations
Is the data you handle sensitive? Why?

Action: As a GDPR compliance measure, the dataset provided must be anonymized (names changed or codified, emails deleted, etc.), as anonymization of personal data (removal or masking of sensitive identifiers) is essential to remain legally compliant.

AI:

The AI Act requires transparency and measurement of the level of risk of my AI. What is my level of risk?
Is my AI protected from attacks?
Action: Testing my AI on typical attacks

Core Anonymization Techniques

- **Generalization**
  - ✓ Replace specific values with broader categories.
- **Suppression**
  - ✓ Remove sensitive data or entire records.
- **Masking**
  - ✓ Hide parts of data values while preserving format.
- **Perturbation**
  - ✓ Introduce controlled noise to modify data.
- **Pseudonymization**
  - ✓ Replace real identifiers with artificial codes.
- **Synthetic Data**
  - ✓ Generate new records mirroring real data's statistics.

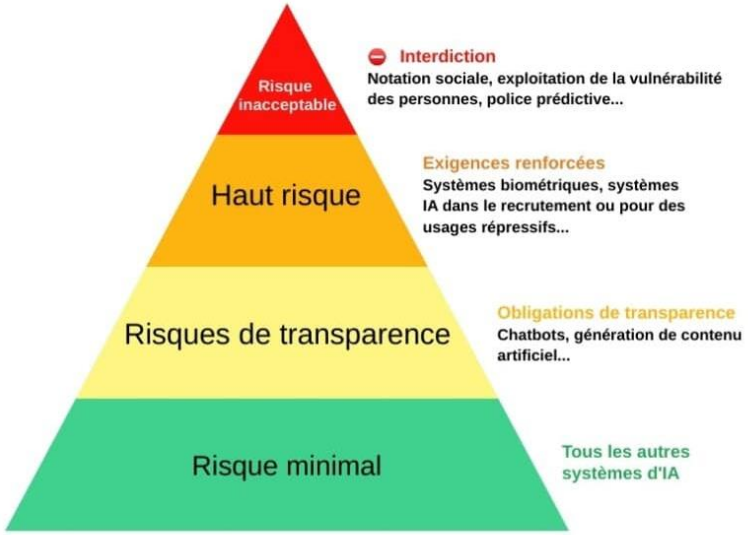

ETHICS AI

▸ **Objective**:

AI Ethics & algorithmic biases: Once the first models start to be built (e.g. a machine learning model that anticipates the risk of resignation from the variables in the dataset), it is crucial to question the fairness of these models.

Responsible AI Challenge: What is a fair and fair model?
Audit predictions: For example, check whether the model treats all employees fairly or whether it shows signs of discrimination.

Outil Opensource : aif360.res.ibm.com

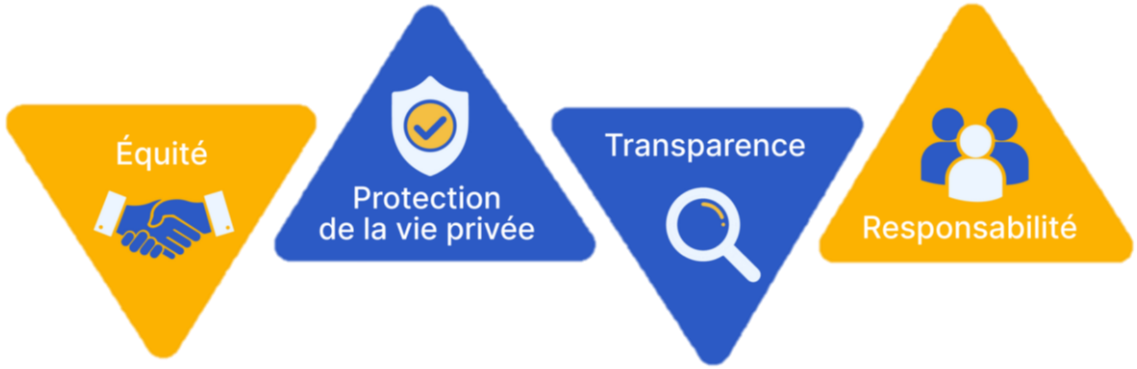

IA FRUGAL

▸ **Obstacle** :

Frugal AI & Resource Efficiency: Once a functional model is established, a new challenge presents itself to you
That of improving the efficiency of your solution without sacrificing too much performance.

Several areas can be explored:
Data frugality: the basic dataset is modest in size
Model Frugality: Comparing Simple vs. Complex Approaches.
Energy sobriety: the calculations remain modest, but this is an opportunity to make them aware of the environmental impact of AI.

We can also discuss frugal techniques: model compression, quantification, etc., with the idea that their solution will one day run on a company server with limited resources.

The frugal AI webinar: Introducing lighter, more durable models instead of always rushing towards complex energy-intensive solutions.
Code Carbon is an open-source library designed to measure and reduce carbon footprint.
Ecologits is a library that allows you to estimate the carbon emission of an LLM model
ComparAI conversational AI comparison tool.

EcoLogits

Estimate and track the environmental footprint of GenAI models at inference.

Made with 💚 by GenAI Impact non-profit.

EXPLAINABLE AI

▸ **Obstacle** :

Explainable AI & Transparency: Here, the challenge is that your solution is not a "black box" that is incomprehensible to the HR managers who are going to use it. The integration of techniques for explaining the models is therefore strongly encouraged:

➔Predictive (structured) model side: If you used a machine learning model, analyze the influencing factors.
For example: "our model predicts that employee X will quit because their satisfaction score is low and they have had many delays recently."
Technically, use XAI tools like LIME or SHAP to explain the predictions.

➔On the generative AI/NLP side: if you have built a chatbot-type tool or an automatic summary system for employee feedback, explainability concerns the transparency of how it works and its limits. You must therefore document how your model generates its responses (e.g. indicate that it is based on GPT-3 or on a fine-tuned model, trained on this type of data) and alert on possible hallucinations or possible errors.
"Golden rules" webinar of explainable AI. Method and tool for model transparency.
▸ Code of conduct for GPAI (AI ACT)

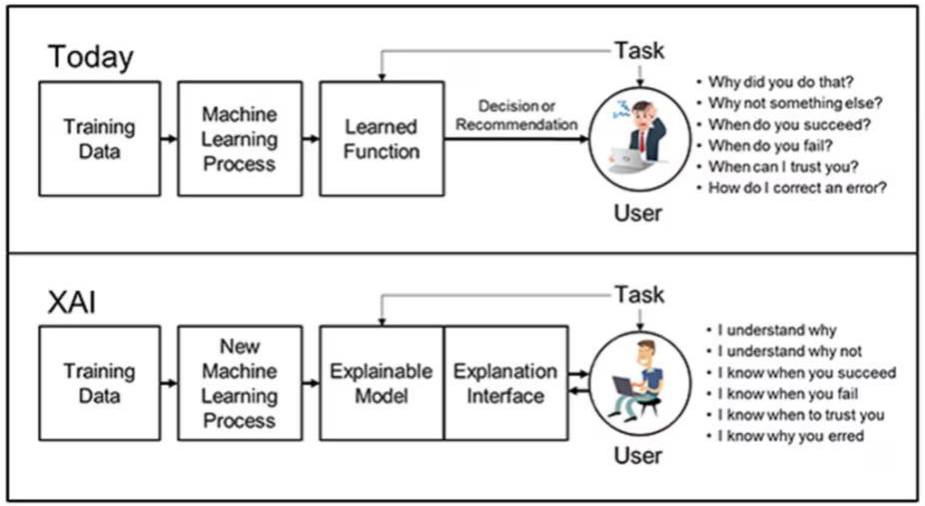

DELIVRABLES

- Model card: why this model and architecture
- Data card : how did you process the data
- Demo
- Pitch